Orçamento de memória e GPU v0 (Jetson Orin Nano, ods-pc)

Responsável: Tony · Medições de 31/10/2026 · Versão 0

1. Objetivo

Registrar quanta memória a placa tem, quanto o sistema consome sozinho e **quanto sobra para rodar modelos e aplicações**. Na Jetson, CPU e GPU compartilham a mesma RAM (memória unificada), então o orçamento de memória e o de GPU são um só: a GPU consome da mesma reserva que o restante do sistema.

2. Plataforma e condições de medição

Item	Valor
Placa	NVIDIA Jetson Orin Nano Engineering Reference Developer Kit Super
Modo de energia (`nvpmodel`)	25W
RAM total	7.620 MB
Swap (zram)	3.810 MB
Sistema	L4T R36.4.7, JetPack 6.2.1, CUDA 12.6
Ferramentas	`free -m` , `ps` , `tegrastats` (intervalo de 1 s, log em `tegra-teste.log`)

Todos os números abaixo valem para o modo de energia de 25W. Em outro modo, o desempenho da CPU e da GPU muda e as medições devem ser refeitas.

3. Memória em repouso

Medida com `free -m`, sem nenhuma carga de teste em execução:

Campo	MB	Significado
Total	7.620	RAM da placa
Usada (`used`)	923	Memória realmente em uso por programas

Campo	MB	Significado
Livre (`free`)	152	Memória sem nenhum uso
Cache (`buff/cache`)	6.545	Cache de arquivos, liberado automaticamente quando necessário
Disponível (`available`)	**6.301**	O que programas novos conseguem usar
Swap usado	154 de 3.810	Quase sem uso

O cache está alto porque a medição foi feita logo depois de gerar a imagem base (arquivos grandes lidos e gravados). Esse cache é recuperável, por isso o valor que vale para o orçamento é o **disponível**, e não o livre.

Ocupado em repouso = total − disponível = 7.620 − 6.301 = 1.319 MB (≈ 17% da RAM).

4. Maiores consumidores em repouso

Memória residente (RSS) dos maiores processos, medida com `ps`:

Processo	RSS (MB)
gnome-shell (área de trabalho)	118
Xorg	66
PM2 (gerenciador de processos)	57
dockerd	54
fwupd	51
snapd	43
containerd	40
tailscaled	35
pulseaudio (usuário ods)	30
ferron (servidor web)	28
clib_cm_bridge.py (monitor)	24
jtop	23

A soma do RSS não é igual à memória usada, pois o RSS conta bibliotecas compartilhadas mais de uma vez e não inclui o kernel. Serve para identificar quem pesa mais, não para somar.

Serviços ativos relacionados ao projeto (pelos nomes): `audio-actuator`, `clib_cm_bridge`, `net_monitor`, `hostapd`, `dnsmasq`. Também estão ativos `ferron`, `playit` e `pm2-root`, cujo responsável precisa ser confirmado.

5. Medição sob carga

Com o `tegrastats` gravando uma linha por segundo, extraíram-se os picos do log:

Métrica	Pico medido
RAM usada	1.648 MB
Uso da GPU (`GR3D_FREQ`)	99%
Swap usado	155 MB
Temperatura máxima	a registrar
Consumo máximo (`VDD_IN`)	a registrar
Carga executada e duração	a registrar

Leitura dos resultados:

- A GPU chegou a 99%, ou seja, a carga a saturou.
- O pico de RAM de 1.648 MB é cerca de 22% da memória total e fica bem abaixo do valor disponível. Em relação aos 923 MB de repouso, a carga acrescentou aproximadamente 0,7 GB (valores de ferramentas diferentes, então são aproximados).
- O swap ficou em 155 MB, praticamente igual ao repouso (154 MB). Não houve pressão de memória.

6. Orçamento de memória v0

Item	MB	% da RAM
RAM total da placa	7.620	100%
Ocupado em repouso (sistema, serviços, Docker, área de trabalho)	1.319	17%

Item	MB	% da RAM
Reserva de segurança (proposta)	1.150	15%
Disponível para modelos e aplicações	**≈ 5.150**	**≈ 68%**

Cálculo: 7.620 − 1.319 − 1.150 = 5.151 MB (≈ 5,0 GiB). A reserva de 15% é deliberadamente conservadora porque a GPU aloca da mesma memória, e um pico de GPU pode ocorrer junto com um pico de CPU.

Comparação: a carga testada (pico total de 1.648 MB) cabe com ampla folga no orçamento. Modelos maiores ou várias aplicações simultâneas ainda não foram medidos e devem ser comparados com os 5.150 MB.

7. Orçamento de GPU

- A GPU não tem memória própria: usa a parte dos **5.150 MB disponíveis** que as aplicações CUDA reservarem. O comando `nvidia-smi` não mostra memória de vídeo dedicada nessa plataforma; o acompanhamento correto é pelo `tegrastats`.
- Uso medido: pico de 99% na carga testada, no modo de 25W.
- Temperatura e consumo: pendentes de extração do log (campos "a registrar" na seção 5) e de confirmação em teste prolongado, previsto na tarefa 7.

8. Regras e limites propostos

Regra	Valor proposto
Limite de memória por aplicação ou container	até 2.500 MB (cerca de metade do disponível); acima disso, só com aprovação do grupo
Aplicações pesadas simultâneas	a soma dos limites não deve passar de 5.150 MB
Alerta de atenção	RAM usada acima de 5.700 MB (75% do total) ou swap acima de 500 MB
Como limitar em Docker	`docker run --memory=2g ...`

Se a memória acabar, o sistema pode encerrar processos para liberar espaço. O swap (zram) funciona como colchão, mas é mais lento e **não substitui RAM**; swap crescendo é sinal de que o orçamento foi ultrapassado.